

LISTA 5

Opis zadania

Rozważmy problem, który przyjmuje jako wejście dwie liczby rzeczywiste z przedziału $[-1, 1]$, różne od zera, i zwraca wartość 1, gdy mają ten sam znak, lub 0 w przeciwnym przypadku. Zaimplementowano algorytm propagacji wstecznej dla tego problemu z dwuwarstwową siecią neuronową, zawierającą cztery bramki w warstwie ukrytej i jedną w warstwie wyjściowej. Przeprowadzono testy dla danych nieznormalizowanych, znormalizowanych normą L1 i L2 oraz dla funkcji aktywacji sigmoid i ReLU.

Wyniki eksperymentów

Normalization	Activation	Learning Rate	Train Accuracy (%)	Test Accuracy (%)
L1 Normalization	relu_sigmoid	0.1	74.5	76
L1 Normalization	relu_sigmoid	0.01	97.75	99
L1 Normalization	relu_sigmoid	0.001	97.88	98.5
L1 Normalization	sigmoid_sigmoid	0.1	97.62	98.5
L1 Normalization	sigmoid_sigmoid	0.01	96.5	96.5
L1 Normalization	sigmoid_sigmoid	0.001	51.38	47
L2 Normalization	relu_sigmoid	0.1	97.75	99
L2 Normalization	relu_sigmoid	0.01	98	99
L2 Normalization	relu_sigmoid	0.001	97.75	99
L2 Normalization	sigmoid_sigmoid	0.1	97.75	99
L2 Normalization	sigmoid_sigmoid	0.01	97.88	99
L2 Normalization	sigmoid_sigmoid	0.001	51.38	47
No Normalization	relu_sigmoid	0.1	74	72.5
No Normalization	relu_sigmoid	0.01	74	74.5
No Normalization	relu_sigmoid	0.001	96.62	96.5
No Normalization	sigmoid_sigmoid	0.1	88.12	86

No Normalization	sigmoid_sigmoid	0.01	84.38	82
No Normalization	sigmoid_sigmoid	0.001	51.38	47

Wnioski

Najlepsze rezultaty uzyskałem dla danych znormalizowanych normą L2 oraz funkcji aktywacji sigmoid, niezależnie od współczynnika uczenia. Zbyt mały współczynnik uczenia (0.001) skutkował wyraźnym spadkiem dokładności dla dużej części konfiguracji. Z kolei wartości 0.01 i 0.1 pozwalały na dawały bardziej efektywne wyniki.